Chapitre 1: Statistique univariée: encodage de tableaux de données brutes, calculs de statistiques descriptives et de tableaux de fréquences

1. Opérateurs mathématiques de base

Opération	Symbole	
Addition	+	
Soustraction	-	
Multiplication	*	
Division	/	
Racine carrée	racine()	
Élever au carré	^2	
Élever au cube	^3	
Élever à une puissance quelconque	^	
Valeur absolue	abs()	

Rappel: n'oubliez pas que lorsqu'on réalise un calcul dans Excel, on commence <u>toujours</u> par introduire le symbole « = » dans la barre de formule.

Ouvrez le fichier *Calculs opérateurs mathématiques Niveau 1.xlsx*. Pour un certain nombre de sujets, on dispose des notes obtenues à 2 cours : mathématiques (note sur 20) et statistiques (note sur 10). Combien y a-t-il de sujets ? Justifiez.

Nous allons utiliser les scores obtenus en math et en statistiques par ces étudiants pour intégrer les opérateurs mathématiques de base.

<u>Addition</u>
Application : = Élément1 + Élément2
<u>Dans la colonne E</u> , appliquez la formule suivante : X_i+3
Afin de vous aider, répondez aux questions suivantes :
 Dans cette formule, de manière générale, à quoi correspond L'élément 1 ? Est-ce une variable ou une constante ? L'élément 2 ? Est-ce une variable ou une constante ?
Commencez par appliquer la formule dans la cellule E2 (vous l'étirerez ensuite dans les cellules E3:E6).
 Quel est le numéro de la ligne de la cellule E2 ? Quel sujet correspond à cette ligne ? Pour ce sujet en particulier, à quoi correspond L'élément 1 ? L'élément 2 ? Combien vaut l'élément 1, dans la cellule E2 ? A-t-on intérêt à introduire directement la valeur de l'élément 1 dans la cellule E2 ? Justifiez :
<u>Rappel</u> : dans Excel, il est toujours préférable d'écrire des formules que l'on peut étirer (cela permet d'éviter les erreurs, et peut faire gagner beaucoup de temps).
<u>Dans la colonne F</u> , appliquez la formule suivante : X_i+Y_i
 Dans cette formule, de manière générale, à quoi correspond L'élément 1 ? Est-ce une variable ou une constante ? L'élément 2 ? Est-ce une variable ou une constante ?
Commencez par appliquer la formule dans la cellule F2 (vous l'étirerez ensuite dans les cellules F3:F6). Dans la cellule F2, à quoi correspond
 L'élément 1 ? → Si c'est pertinent, quelle est la référence de la cellule contenant sa valeur ? L'élément 2 ? → Si c'est pertinent, quelle est la référence de la cellule contenant sa valeur ?
La formule à introduire dans la cellule F2 est donc :

<u>Soustraction</u>	<u>n</u>
Application	: = Élément1 - Élément2
Dans la color	nne G, appliquez la formule suivante : Xi - 3
0	cette formule, de manière générale, à quoi correspond L'élément 1 ? Est-ce une variable ou une constante ? L'élément 2 ? Est-ce une variable ou une constante ?
	par appliquer la formule dans la cellule G2 (vous l'étirerez ensuite dans G3:G6). Dans la cellule G2, à quoi correspond
	L'élément 1 ? → Si c'est pertinent, quelle est la référence de la cellule contenant sa valeur ? L'élément 2 ? → Si c'est pertinent, quelle est la référence de la cellule contenant sa valeur ?
La formule à	introduire dans la cellule G2 est donc :
<u>Dans la color</u>	nne H, appliquez la formule suivante : X, - X,
0	cette formule, de manière générale, à quoi correspond L'élément 1 ? Est-ce une variable ou une constante ? L'élément 2 ? Est-ce une variable ou une constante ?
	par appliquer la formule dans la cellule H2 (vous l'étirerez ensuite dans H3:H6). Dans la cellule H2, à quoi correspond
	L'élément 1 ? → Si c'est pertinent, quelle est la référence de la cellule contenant sa valeur ? L'élément 2 ?

La formule à introduire dans la cellule H2 est donc :

sa valeur ?

Multiplication

Application	: = élément1 * élément2
Dans la color	nne I, appliquez la formule suivante : $5 imes X_i$
0	cette formule, de manière générale, à quoi correspond L'élément 1 ? Est-ce une variable ou une constante ? L'élément 2 ? Est-ce une variable ou une constante ?
· ·	par appliquer la formule dans la cellule I2 (vous l'étirerez ensuite dans :3:I6). Dans la cellule I2, à quoi correspond
	L'élément 1 ?
La formule à	introduire dans la cellule I2 est donc :
Dans la color	nne $oldsymbol{J}$, appliquez la formule suivante : $oldsymbol{X}_i imes oldsymbol{Y}_i$
0	cette formule, de manière générale, à quoi correspond L'élément 1 ? Est-ce une variable ou une constante ? L'élément 2 ? Est-ce une variable ou une constante ?
	par appliquer la formule dans la cellule J2 (vous l'étirerez ensuite dans [3:J6). Dans la cellule J2, à quoi correspond
	L'élément 1 ? → Si c'est pertinent, quelle est la référence de la cellule contenant sa valeur ? L'élément 2 ? → Si c'est pertinent, quelle est la référence de la cellule contenant sa valeur ?
La formule à	introduire dans la cellule J2 est donc :

<u>Division</u>	
Application : = élément1 / élément2	
Dans la colonne K, appliquez la formule suivante : $\frac{5}{X_i}$	
 Dans cette formule, de manière générale, à quoi correspond L'élément 1 ? Est-ce une variable ou une constante ? L'élément 2 ? Est-ce une variable ou une constante ? 	
Commencez par appliquer la formule dans la cellule K2 (vous l'étirerez ensuite dar les cellules K3:K6). Dans la cellule K2, à quoi correspond	IS
 ○ L'élément 1? → Si c'est pertinent, quelle est la référence de la cellule contenar sa valeur? ○ L'élément 2? → Si c'est pertinent, quelle est la référence de la cellule contenar sa valeur? 	
La formule à introduire dans la cellule K2 est donc :	
Dans la colonne L, appliquez la formule suivante : $\frac{X_i}{Y_i}$	
 Dans cette formule, de manière générale, à quoi correspond L'élément 1 ? Est-ce une variable ou une constante ? L'élément 2 ? Est-ce une variable ou une constante ? 	
Commencez par appliquer la formule dans la cellule L2 (vous l'étirerez ensuite dar les cellules L3:L6). Dans la cellule L2, à quoi correspond	ıs
 ○ L'élément 1 ? → Si c'est pertinent, quelle est la référence de la cellule contenar sa valeur ? ○ L'élément 2 ? → Si c'est pertinent, quelle est la référence de la cellule contenar 	

La formule à introduire dans la cellule L2 est donc :

sa valeur?.....

Élever un nombre à une puissance k

Application : = élément^k
<u>Dans la colonne M,</u> appliquez la formule suivante : X_i^2
 Dans cette formule, de manière générale, à quoi correspond L'élément? Est-ce une variable ou une constante? k? Est-ce une variable ou une constante?
Commencez par appliquer la formule dans la cellule M2 (vous l'étirerez ensuite dans les cellules M3:M6). Dans la cellule M2, à quoi correspond
 L'élément ? → Si c'est pertinent, quelle est la référence de la cellule contenant sa valeur ? k ? → Si c'est pertinent, quelle est la référence de la cellule contenant
La formule à introduire dans la cellule M2 est donc :
Dans la colonne N, appliquez la formule suivante : $oldsymbol{Y}_i^{X_i}$
 Dans cette formule, de manière générale, à quoi correspond L'élément? Est-ce une variable ou une constante ? k? Est-ce une variable ou une constante ?
Commencez par appliquer la formule dans la cellule N2 (vous l'étirerez ensuite dans les cellules N3: N6). Dans la cellule N2, à quoi correspond
 ○ L'élément ? → Si c'est pertinent, quelle est la référence de la cellule contenant sa valeur ? ○ k ?
 → Si c'est pertinent, quelle est la référence de la cellule contenant
La formule à introduire dans la cellule N2 est donc :

Racine carrée

Application : = racine(élément)

Dans la colonne O, appliquez la formule suivante : $\sqrt{X_i}$

- Dans cette formule, de manière générale, à quoi correspond ...
 - o L'élément? Est-ce une variable ou une constante?

Commencez par appliquer la formule dans la cellule O2 (vous l'étirerez ensuite dans les cellules O3:O6). Dans la cellule O2, à quoi correspond...

o L'élément?......

→ Si c'est pertinent, quelle est la référence de la cellule contenant sa valeur ?

La formule à introduire dans la cellule O2 est donc :

Valeur absolue

Rappel : en langage mathématiques, les valeurs absolues s'expriment par des barres verticales |...|.

 $Ex.: |X_i| = valeur absolue de X_i$

Application : = abs(élément)

Dans la colonne P, appliquez la formule suivante : $|Y_i|$

- Dans cette formule, de manière générale, à quoi correspond ...
 - o L'élément? Est-ce une variable ou une constante?

Commencez par appliquer la formule dans la cellule P2 (vous l'étirerez ensuite dans les cellules P3:P6). Dans la cellule P2, à quoi correspond...

o L'élément?......

→ Si c'est pertinent, quelle est la référence de la cellule contenant sa valeur ?

La formule à introduire dans la cellule P2 est donc :

Exercices

1) Exercice 1

Objectif : appliquer les opérations mathématiques de base.

Ouvrez le fichier *Calculs opérateurs mathématiques Niveau 2.xlsx*. Vous allez devoir appliquer les différentes opérations que vous venez de revoir (mais parfois, en les combinant).

Astuce : pensez bien à vous demander, pour chaque élément de chaque formule, s'il s'agit d'un élément variable d'un sujet à l'autre ou d'une constante.

<u>Dans la colonne E</u>, appliquez la formule suivante : $(X_i - 5)^2$

<u>Dans la colonne F</u>, appliquez la formule suivante : $(Y_i + 3)^3$

<u>Dans la colonne G</u>, appliquez la formule suivante : $X_i - |Y_i|$

<u>Dans la colonne H</u>, appliquez la formule suivante : $X_i (Y_i + 2)$

<u>Dans la colonne I</u>, appliquez la formule suivante : $\sqrt{\frac{X_i}{2}}$

<u>Dans la colonne J</u>, appliquez la formule suivante : $\frac{(X_i+1)}{(2\times Y_i)}$

Dans la colonne K, appliquez la formule suivante : $5 \times (X_i - 3)^2$

<u>Dans la colonne L</u>, appliquez la formule suivante : $|Y_i - (3 \times X_i)|$

2) Exercice 2

Objectif : application des opérations mathématiques de base, avec références à des cellules figées (implique l'introduction de \$ dans les formules)

Ouvrez le fichier Calculs opérateurs mathématiques Niveau 3.xlsx.

Commencez par calculer les sommes (cellules C8 et D8) et moyennes (cellules C9 et D

9) des variables X_i et Y_i . Tous les calculs que vous devez effectuer dans cette feuille impliqueront de faire référence à ces cellules.

<u>Dans la colonne E</u>, appliquez la formule suivante : $X_i - \sum_{i=1}^n X_i$

<u>Dans la colonne F</u>, appliquez la formule suivante : $(Y_i + \sum_{i=1}^n Y_i)^3$

<u>Dans la colonne G</u>, appliquez la formule suivante : $(X_i - \overline{X}_i) + 5$

<u>Dans la colonne H</u>, appliquez la formule suivante : $(\sum_{i=1}^{n} X_i)^2 + Y_i^2$

2. Fonctions statistiques

Voici un rappel des fonctions de base vue lors du premier cours :

Fonction	Notation Excel
Moyenne	MOYENNE()
Médiane	MEDIANE()
Mode	MODE.SIMPLE ()
Minimum	MIN()
Maximum	MAX()
Centile	CENTILE()
Quartile	QUARTILE()
Écart moyen absolu	ECART.MOYEN()
Variance	VAR.P()
Écart-type	ECARTYPE.P()
Asymétrie	COEFFICIENT.ASYMETRIE()
Kurtosis	KURTOSIS()
Somme	SOMME()
Compter le nombre d'observations	NBVAL()
Compter les observations qui répondent à un critère	NB.SI()

1) Ouvrez le fichier *Personnalité.xlsx*. Pour 11 traits de personnalité différents, on a attribué un score à divers participants. Tous les scores sont compris entre 0 et 10 (chiffres ronds). Un score de 0 signifie que le trait de personnalité est à l'opposé du sujet. Un score de 10 signifie au contraire que le trait correspond tout à fait à l'individu.

Exemple : un individu ayant le score de 10 à la variable P_i est un individu extrêmement bavard ; un individu ayant un score de 2 à la variable Z_i est un individu très poli.

Objectif : s'entraîner à utiliser les fonctions

- + donner du sens aux indicateurs statistiques.
- 1.1. Toutes ces variables sont mesurées sur un même type d'échelle. Lequel?.....
- 1.2. Toutes ces variables ont le même nombre de modalités :
 - a. Combien de modalités ?
 - b. Citez-les toutes:

1.3.	Parmi les indicateurs mentionnés dans la feuille <i>Statistiques</i> descriptives, y en a-t-il certains qui ne peuvent être calculés pour ce type d'échelle ? (Si oui, citez-les).
1.4.	Dans la feuille <i>Statistique descriptives</i> , complétez toutes les cellules colorées . Arrondissez toutes vos réponses à <u>3 décimales</u> .
type d'éc il n'est po	e: dans la mesure où toutes ces variables sont mesurées sur le même helle, il n'est pas nécessaire d'introduire de condition (autrement dit, as nécessaire d'utiliser la fonction <i>SI()</i>). On vous demande donc juste quer correctement l'une des fonctions de la liste fournie, p.9.
1.5.	Sur base des réponses trouvées dans les cases colorées de la feuille Statistiques descriptives, répondez aux questions suivantes.
• • • • • • • • • • • • • • • • • • •	Déprimés ou heureux ?

- Entre les variables U_i et V_i , quelle est celle qui a le plus grand écart interquartile?
- Entre les variables Q_i et U_i , quelle est celle qui présente la plus forte asymétrie ?
- La variable R_i est-elle plus ou moins pointue qu'une distribution normale ? Justifiez:
- Pour la variable U_i, pour certains sujets, aucun score n'a été attribué.
 Combien cela concerne-t-il de sujets? Justifiez en comparant le nombre de lignes du tableau de données brutes avec l'un des indicateurs statistiques calculés:

.....

2) Ouvrez le fichier Calculs opérateurs mathématiques Niveau 4.xlsx. Cette fois, il ne vous est pas demandé de calculer les fonctions dans une cellule à part (contrairement à ce que vous aviez fait pour le fichier Calculs opérateurs mathématiques Niveau 3.xlsx). Il vous est demandé d'introduire les fonctions directement dans les formules.

Objectif : combiner l'usage des fonctions et des opérateurs mathématiques de base

<u>Dans la colonne G</u>, appliquez la formule suivante : $X_i - \overline{X}_i$

Dans la colonne H, appliquez la formule suivante : $|Y_i - \overline{Y}_i|$

<u>Dans la colonne I</u>, appliquez la formule suivante : $\frac{|W_i - \overline{W_l}|}{n}$

<u>Dans la colonne J</u>, appliquez la formule suivante : $\frac{(\mathbf{Z}_i - \overline{\mathbf{Z}}_l)^2}{n}$

3) Ouvrez le fichier Eau.minerale.xlsx.

Le fichier contient un tableau qui récapitule la composition chimique d'un certain nombre d'eaux minérales classées par pays (cf. Tomassone, Dervin & Masson 1993 BIOMÉTRIE, Modélisation des phénomènes biologiques, Masson, Paris, 553 p.). Les variables sont les suivantes :

- Nom = la dénomination d'origine de la source
- Pays = le pays d'origine
- Cl = la composition en chlore
- Ca = la composition en calcium
- Mg = la composition en manganèse
- Ni = la composition en nitrate
- SO4 = la composition en sulfate
- HCO3 = la composition en gaz carbonique

Objectif : combiner l'usage des fonctions et des opérateurs mathématiques de base

- 3.1. Dans la feuille *Statistiques descriptives*, commencez par préciser pour chaque variable si elle est de type « qualitatif » ou « quantitatif ».
- 3.2. Dans la feuille Statistiques descriptives, déterminez une formule, que vous pourrez étirez dans les cellules C4:H4 (toutes ces cellules se rapportent à des variables quantitatives, il n'est donc pas nécessaire d'inclure de condition dans la fonction), telle que la réponse soit la valeur en-deçà de laquelle les valeurs sont jugées extrêmement basses.

<u>Pour rappel</u>: on considère qu'une valeur est extrêmement basse si elle se situe à Q1-(1.5*écart interquartile).

3.3. Dans la feuille Statistiques descriptives, déterminez une formule, que vous pourrez étirez dans les cellules C5:H5 (toutes ces cellules se rapportent à des variables quantitatives, il n'est donc pas nécessaire d'inclure de condition dans la fonction), telle que la réponse soit la valeur au-delà de laquelle les valeurs sont jugées extrêmement hautes.

<u>Pour rappel</u>: on considère qu'une valeur est extrêmement haute si elle se situe à Q3+(1.5*écart interquartile).

3. Les formules conditionnelles

Rappel : La fonction conditionnelle renvoie une réponse différente suivant qu'une condition donnée soit vraie ou fausse. Elle présente la structure suivante :

SI(condition logique ; réponse si vrai ; réponse si faux)

Elle est constituée de 3 arguments, soit séparés par un « ; »

 Condition logique = une affirmation que l'on pose qui sera soit vraie, soit fausse

- Réponse si vrai = ce qu'Excel doit appliquer si la condition logique (premier argument) est vraie.
- Réponse si faux = ce qu'Excel doit appliquer si la condition logique (premier argument) est fausse.

Les conditions logiques consistent généralement à comparer deux éléments. Les symboles de comparaisons les plus fréquents sont les suivants :

Comparaison	Symbole	
Égal	=	
Plus grand ou égal	>=	
Strictement plus grand	>	
Plus petit ou égal	<=	
Strictement plus petit	<	
Différent de	<>	

Exercices

Ouvrez le fichier Examen2017.xlsx. Pour un certain nombre d'étudiants, on connait la note obtenue (sur 20) à deux parties du même examen : une partie théorique - $Th.(X_i)$, et une partie pratique - $Tp.(Y_i)$.

- 2) Dans les cellules D2:D26, calculez la note finale (Z_i) obtenue par chaque étudiant, sachant que cette note est la moyenne entre la note obtenue en théorie et celle obtenue en pratique.
- 3) Dans les cellules E2:E26, indiquez pour chaque étudiant s'il a « raté » ou « réussi » son examen :
 - a. Si la note finale obtenue par un étudiant est supérieure ou égale à 10, la décision doit être « réussi ».
 - b. Si la note finale obtenue par un étudiant est strictement inférieure à 10, la décision doit être « raté ».
- 4) Dans les cellules F2:F26, imprimez un commentaire pour chaque étudiant.
 - a. S'il a obtenu une note strictement inférieure à 10, imprimez « Quel dommage! «
 - b. S'il a obtenu une note supérieure ou égale à 16, imprimez le commentaire : « Excellent! »
 - c. S'il a obtenu une note supérieure ou égale à 10 mais inférieure à 16, imprimez « Félicitations! »

4. La fonction SOMMEPROD

Ouvrez le fichier achatsxlsx. 11 clients différents sont rentrés dans une librairie entre 10h45 et 11h. Chacun a acheté un ou plusieurs exemplaires d'un article dont le prix à la pièce est fourni dans la base de données (variable Z_i). On constate par exemple que le premier client a acheté un article qui coûte 0,50 cents en un seul exemplaire, et a donc dépensé 50 cents. Le deuxième client a acheté 3 articles qui coûtent 1,80 euros/pièce, et a donc dépensé 5,40 euros, etc.

- 1. Dans les cellules D2:D12, déterminez la quantité d'argent dépensée durant ce laps de temps par chaque client.
- 2. Dans la cellule D13, déterminez la somme totale d'argent dépensée par l'ensemble des clients entre 10h45 et 11h, en utilisant l'information contenue dans les cellules D2:D12. Quelle fonction allez-vous utiliser pour ce faire?
- 3. Au final, combien de cellules avez-vous dû utiliser pour calculer l'information contenue en D13 ?
- 4. La fonction = **SOMMEPROD()** permet de faire exactement la même chose, mais en utilisant <u>une seule cellule</u>. Cette formule permet d'effectuer le produit de deux valeurs situées sur une même ligne mais dans des colonnes différentes, et d'en additionner les résultats, le tout en une seule cellule.

Nous allons appliquer cette fonction à notre exercice. Voici la formule que nous souhaitons appliquer, via SOMMEPROD : $\sum_{i=1}^{n} (X_i \times Z_i)$

Pour vous aider, répondez aux questions suivantes :

- 4.1. Quelle est la multiplication que nous souhaitons appliquer pour chaque sujet?
- 4.2. Pour rappel, voici la manière dont on applique une multiplication dans Excel :

Application : = élément1 * élément2

Complétez le tableau ci-dessous, en indiquant pour chaque sujet, la référence de la cellule qui contient respectivement les valeurs des éléments 1 et 2 de la multiplication à appliquer (pour illustration, la première ligne a déjà été complétée).

	Élément 1	Élément 2
Sujet		
1	B2	C2
2		
3		
4		
5		
6		
7		
8		
9		
10		
11		

- 4.3. Quelle est la plage de données qui contient, pour l'ensemble des sujets, les valeurs de l'élément 1 (= l'argument *Matrice1* dans le rappel de fonction ci-dessous)?
- 4.4. Quelle est la plage de données qui contient, pour l'ensemble des sujets, les valeurs de l'élément 2 (= l'argument *Matrice2* dans le rappel de fonction ci-dessous)?
- 4.5. Appliquez correctement la fonction SOMMEPROD, dans la cellule D14.

Application : = SOMMEPROD(Matrice1; Matrice2)

- Matrice1 = la plage de donnée qui contient, pour l'ensemble des sujets, les scores qui correspondent à l'élément 1 de la multiplication.
- Matrice2 = la plage de donnée qui contient, pour l'ensemble des sujets, les scores qui correspondent à l'élément 2 de la multiplication.

Obtenez-vous la même réponse que dans la cellule D13 ? Si oui, félicitations!